



Nama(NIM): Fathan Andi Kartagama (122140055), Rahmat Aldi Nasda (122140077),
Dito Rifki Irawan (122140153)
Mata Kuliah: Deep Learning (IF25-40401)
Tugas: Eksperimen Arsitektur ResNet-34
Tanggal: October 3, 2025

1 Pendahuluan

Residual Network (ResNet) oleh He et al. (2016) memecahkan masalah degradasi pada deep neural networks melalui skip connection sederhana: $y = F(x) + x$. Paper ini mengeksplorasi ResNet-34 secara sistematis melalui eksperimen: (1) Plain-34 baseline untuk membuktikan degradasi, (2) ResNet-34 untuk menunjukkan efektivitas residual learning, dan (3) modifikasi arsitektur (SE-Block, pre-activation) untuk analisis mendalam. Dataset: 5 kelas Makanan Indonesia, split 80:20 (train:val), total 887 images training, 221 validation.

2 Metodologi

2.1 Setup Eksperimen

Tabel 1: Setup Eksperimen

Parameter	Value
Training Hyperparameters	
Epochs	15
Batch Size	32
Learning Rate	1×10^{-4}
Optimizer	AdamW
Weight Decay	1×10^{-4}
Loss Function	CrossEntropyLoss
Data Preprocessing	
Image Size	224×224
RandomHorizontalFlip	p = 0.5
ColorJitter	brightness/contrast/saturation = 0.2
Normalization Mean	[0.485, 0.456, 0.406]
Normalization Std	[0.229, 0.224, 0.225]
Hardware & Reproducibility	
Device	CUDA GPU
Precision	Mixed (fp16/bf16)
Random Seed	42

Tabel 2: Arsitektur Model yang Diuji

Model	Deskripsi Arsitektur
Plain-34	Jaringan dasar 34 layer tanpa skip connection. Setiap blok berisi dua Conv3x3 dengan BN dan ReLU. Karena tidak ada shortcut, model sulit dilatih saat semakin dalam
ResNet-34	Sama dengan Plain-34, tapi setiap blok punya skip connection ($x + F(x)$). Fitur utama adalah shortcut yang menjaga aliran informasi dan gradient, sehingga training lebih stabil
Pre-activation ResNet-34	Modifikasi ResNet-34 dengan urutan BN-ReLU sebelum Conv, serta tanpa aktivasi setelah penjumlahan skip
SE-ResNet-34	ResNet-34 yang ditambah modul Squeeze-and-Excitation. Modul ini memberi perhatian (attention) pada channel penting, memperkuat fitur relevan, dan hanya menambah parameter sedikit ($< 1\%$).
SE-Preact ResNet-34	Kombinasi pre-activation block dengan SE module. Tujuannya menggabungkan jalur gradient yang lebih bersih dengan channel attention, meski pada depth 34 layer keuntungannya terbatas.

2.2 Arsitektur Model

3 Hasil dan Analisis

3.1 Q1: Apa itu Degradation Problem?

Degradation adalah masalah di mana jaringan yang lebih dalam justru memberikan hasil lebih buruk daripada jaringan yang lebih dangkal. Ini bukan masalah overfitting (model terlalu menghafal data training), melainkan model kesulitan untuk belajar sama sekali. Akurasi training-nya sendiri sudah rendah, bukan cuma akurasi validasi

Bukti Empiris (Plain-34):

Tabel 3: Performa Plain-34 - Bukti Degradation

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	1.618	20.86%	1.611	19.91%
5	1.567	25.48%	1.710	28.96%
10	1.120	52.99%	1.162	57.01%
14	0.826	68.09%	0.877	70.59%
15	0.841	67.87%	1.138	61.54%

Analisis Degradation:

1. **Susah Belajar:** Plain-34 tidak mampu menurunkan train loss cukup rendah, tanda optimizer kesulitan
2. **Performa Anjlok Parah:** Terjadi collapse di epoch 15, akurasi validasi turun drastis dan loss naik
3. **Belajar Tidak Stabil:** Val loss berfluktuasi tajam, training tidak konsisten
4. **Generalisasi Buruk:** Akurasi validasi rendah, hanya sedikit lebih baik dari tebak acak

Penyebab Degradation:

1. **Vanishing Gradient:** Pada jaringan yang sangat dalam, sinyal error yang dikirim balik dari output ke layer awal makin lama makin melemah. Akibatnya, layer awal tidak mendapatkan informasi yang cukup jelas untuk memperbaiki bobotnya
2. **Optimization Difficulty:** Plain-34 punya parameter yang sangat banyak. Proses penyesuaian semua parameter ini sekaligus membuat optimizer kesulitan menemukan kombinasi yang baik, sehingga sering terjebak di solusi yang kurang optimal

3. **Information Loss:** Karena data terus-menerus ditransformasi lewat banyak layer, informasi penting dari input awal semakin hilang atau berubah. Akhirnya, layer terakhir menerima representasi yang sudah terlalu jauh dari bentuk aslinya, sehingga pembelajaran menjadi lebih sulit

3.2 Q2: Bagaimana Residual Connection Mengatasi Degradation?

Residual connection bekerja dengan cara melewatkan informasi asli dari input langsung ke layer yang lebih dalam melalui skip connection. Mekanisme ini membantu menjaga informasi penting tidak hilang dan membuat aliran gradient tetap kuat saat backpropagation, sehingga jaringan yang lebih dalam bisa dilatih tanpa mengalami masalah degradasi performa

Bukti Efektivitas (ResNet-34 vs Plain-34):

Tabel 4: Perbandingan ResNet-34 vs Plain-34

Epoch	ResNet Train Acc	Plain Train Acc	ResNet Val Acc	Plain Val Acc
1	32.24%	20.86%	29.41%	19.91%
5	81.06%	25.48%	66.97%	28.96%
8	90.42%	44.08%	80.09%	52.04%
10	91.66%	52.99%	80.09%	57.01%
13	96.96%	63.92%	81.00%	64.71%
14	97.29%	68.09%	83.71%	70.59%
15	97.07%	67.87%	74.66%	61.54%

Key Improvements:

1. **Akurasi jauh lebih tinggi:** ResNet jauh mengungguli Plain di train dan val acc
2. **Lebih Cepat Konvergen:** ResNet capai performa baik dalam beberapa epoch, Plain lambat
3. **Training Lebih Stabil:** Loss ResNet turun mulus, Plain fluktuatif
4. **Tidak Collapse Parah:** ResNet hanya drop wajar, Plain jatuh drastis

Mengapa Residual Connection Bekerja?

1. **Gradient Highway:** Skip connection memberi jalur langsung bagi gradient sehingga tidak mudah hilang
2. **Identity Mapping:** Jika blok gagal belajar, jaringan tetap bisa meneruskan input apa adanya, jadi tidak lebih buruk dari model dangkal
3. **Mudah Dioptimasi:** Lebih gampang belajar perubahan kecil dari input (residual) daripada belajar pemetaan penuh
4. **Ensemble Effect:** Skip connection menciptakan banyak jalur belajar, membuat training lebih kuat dan stabil

3.3 Q3: Analisis Modifikasi Arsitektur

3.3.1 Pre-activation ResNet-34

Modifikasi:

Tabel 5: Perbedaan Standard vs Pre-activation ResNet

Arsitektur	Block Structure
Standard ResNet	Conv-BN-ReLU-Conv-BN + skip → ReLU
Pre-activation ResNet	BN-ReLU-Conv-BN-ReLU-Conv + skip (no activation after add)

Hasil: Pre-activation lebih stabil di tengah training, tapi standard ResNet memberi akurasi puncak lebih tinggi

Analisis: Untuk jaringan sedang seperti ResNet-34, skip connection biasa sudah cukup, sehingga keunggulan pre-activation belum terlalu terasa

Tabel 6: Pre-activation vs Standard ResNet-34

Epoch	Preact Train	Std Train	Preact Val	Std Val
1	35.63%	32.24%	41.63%	29.41%
5	78.24%	81.06%	67.87%	66.97%
10	92.78%	91.66%	81.45%	80.09%
11	96.39%	93.80%	85.52%	80.54%
13	97.63%	96.96%	85.97%	80.99%
14	97.63%	97.29%	81.45%	83.71%
15	97.29%	97.07%	80.54%	74.66%

3.3.2 SE-ResNet-34

Mekanisme: Squeeze-and-Excitation bekerja dengan merangkul informasi tiap channel, lalu mempelajari seberapa penting masing-masing channel, dan akhirnya menyesuaikan bobotnya sehingga fitur yang relevan dikuatkan dan yang kurang penting dilemahkan

Tabel 7: SE-ResNet-34 vs Standard ResNet-34

Epoch	SE Train	Std Train	SE Val	Std Val
1	33.37%	32.24%	42.53%	29.41%
5	78.47%	81.06%	59.28%	66.97%
10	92.67%	91.66%	61.54%	80.09%
14	95.94%	97.29%	82.81%	83.71%
15	96.05%	97.07%	87.33%	74.66%

Hasil Menarik: SE-ResNet mencapai akurasi validasi tertinggi **87.33%** dan lebih tahan terhadap overfitting dibanding ResNet standar

Analisis: SE-Block membantu generalisasi dengan fokus pada fitur penting, meski awalnya training agak tidak stabil. Pada tahap akhir, recalibration channel memberi keuntungan besar dengan tambahan parameter yang sangat kecil.

3.3.3 SE + Pre-activation

Kombinasi: SE-Block + Pre-activation ResNet-34.

Tabel 8: SE-Preact vs SE-Standard

Epoch	SE-Preact Train	SE-Std Train	SE-Preact Val	SE-Std Val
14	98.31%	95.94%	83.26%	82.81%
15	97.52%	96.05%	81.45%	87.33%

Hasil: SE-Preact performanya lebih rendah dibanding SE-Standard, sehingga pada dataset ini penambahan pre-activation tidak memberi keuntungan berarti

3.4 Q4: Perbandingan Komprehensif

Analisis Detail:

1. **Residual Connection Menjadi Kunci Utama:** Pada Plain-34, model gagal belajar dengan baik, akurasi validasi hanya **70.59%** dan training **68.09%**. Dengan Residual Connection, performa langsung melonjak ke **83.71%** validasi dan **97.29%** training. Ini membuktikan bahwa skip connection bukan sekadar trik, tapi solusi fundamental untuk degradasi
2. **SE-Block paling unggul:** Model SE-ResNet mencatat akurasi validasi tertinggi **87.33%** di epoch 15. Mekanisme channel attention membuat model lebih fokus ke fitur penting sehingga lebih tahan terhadap noise dan overfitting

Tabel 9: Summary Semua Model (Best Performance)

Model	Best Epoch	Train Acc	Val Acc	Gain vs Plain
Plain-34	14	68.09%	70.59%	-
ResNet-34	14	97.29%	83.71%	+18.6%
Pre-activation	11	96.39%	85.52%	+21.1%
SE-ResNet	15	96.05%	87.33%	+23.7%
SE-Preact	13	97.63%	85.97%	+21.7%

3. **Pre-activation unggul di pertengahan training:** ResNet dengan pre-activation sempat mengungguli ResNet standar di epoch 11 **85.52% vs 80.54%**. Namun, menjelang akhir training ResNet standar justru melampaui **83.71% vs 81.45%**
4. **SE-Preact:** Menggabungkan SE dan pre-activation menghasilkan performa yang konsisten tinggi **85.97%**, tetapi tetap tidak bisa mengalahkan SE-ResNet standar. Ini menunjukkan bahwa pada kedalaman 34 layer, pre-activation tidak memberi tambahan manfaat signifikan ketika sudah ada SE-Block.
5. **Ukuran dataset berpengaruh:** Dengan dataset kecil (1108 gambar), regularisasi sangat penting. SE-Block secara alami bertindak sebagai regularizer lewat channel attention, sehingga model lebih tahan overfitting. Terbukti di epoch 15, ResNet standar jatuh ke **74.66%**, sementara SE-ResNet justru mencapai puncak **87.33%**.

4 Referensi dan Lampiran

- K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Las Vegas, NV, USA, Jun. 2016, pp. 770–778.
- K. He, X. Zhang, S. Ren, and J. Sun, "Identity mappings in deep residual networks," in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, Amsterdam, The Netherlands, Oct. 2016, pp. 630–645.
- J. Hu, L. Shen, and G. Sun, "Squeeze-and-excitation networks," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Salt Lake City, UT, USA, Jun. 2018, pp. 7132–7141.
- A. Veit, M. Wilber, and S. Belongie, "Residual networks behave like ensembles of relatively shallow networks," in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, Barcelona, Spain, Dec. 2016.
- PyTorch Documentation: <https://pytorch.org/docs/stable/>
- Github Repo: <https://github.com/urbaee/Deep-Learning>

5 Peran dan Kontribusi AI Assistant

5.1 Prompt dan Masalah yang Diajukan

Pada proyek ini, AI Assistant digunakan untuk membantu implementasi Squeeze-and-Excitation (SE) Block dengan prompt mengenai cara mengintegrasikan channel attention mechanism ke dalam arsitektur ResNet34. AI juga diminta menjelaskan konsep pre-activation ResNet dan perbedaannya dengan ResNet standar untuk meningkatkan pemahaman teoritis kelompok.

5.2 Bagian Kode yang Dihasilkan/Dibantu AI

AI membantu menghasilkan implementasi awal SE Block yang kemudian diintegrasikan ke dalam model ResNet34, serta memberikan penjelasan mengenai struktur pre-activation pada residual connection. Selain itu, AI membantu menyusun struktur kode untuk visualisasi confusion matrix dan kurva akurasi/loss yang digunakan dalam analisis hasil eksperimen.

5.3 Verifikasi dan Modifikasi Output AI

Kelompok memverifikasi output AI dengan menjalankan kode secara bertahap dan membandingkan dengan paper ResNet original serta paper SE-Net untuk memastikan kesesuaian implementasi. Modifikasi dilakukan pada hyperparameter seperti reduction ratio pada SE Block (diubah menjadi 16) dan learning rate scheduler untuk mengoptimalkan performa model. Integrasi dilakukan dengan menyesuaikan dimensi tensor output SE Block agar kompatibel dengan arsitektur ResNet34 yang sudah ada, serta menambahkan logging untuk monitoring training process.

5.4 Link Percakapan dengan AI

- ChatGPT: <https://chatgpt.com/share/68da46c1-1d20-8013-9dc8-074e5306abc0>
- Qwen AI: <https://chat.qwen.ai/s/5501a768-29c5-4745-8a1e-674b85f1c3b9?fev=0.0.219>